

Proceso de ajuste del modelo TAR para la estimación del efecto *Pass through*

El presente apartado **do sirve tiene** como finalidad detallar el proceso de ajuste del modelo TAR utilizado para la estimación del efecto pass-through del tipo de cambio para Guatemala por lo que se omite la explicación del modelo en cuestión y se concentra únicamente en el código y proceso de estimación.

El punto de partida para el ajuste del modelo TAR es conocer los umbrales que separan cada uno de los regímenes inflacionarios. Debido al hecho que estos se desconocen el primer paso consiste en la estimación de estos. El procedimiento a seguir será el propuesto por Chan(1993) el cual requiere de 3 pasos a seguir.

1. Se ordenan de menor a mayor las observaciones de la variable que define el estado del sistema y se procede a eliminar el 30% de las observaciones extremas¹. Este será el conjunto de umbrales posibles.
2. Se ajusta el modelo TAR teórico por cada uno de los umbrales y se captura de cada modelo la suma de residuos al cuadrado SSR.
3. Las SSR son función del umbral utilizado para el ajuste del modelo por lo que se grafican SSR contra umbrales obteniendo así la función SSR. Si uno de los umbrales dentro del conjunto es el verdadero umbral del modelo la SSR disminuirá en la meda en la cual se aproxima al umbral. Si hay más de un umbral la función SSR tendrá tantos mínimos como umbrales a considerar dentro del modelo.

Luego de estimados los umbrales se procede **a justar el m**odelo TAR con los umbrales seleccionados.

Modelo teórico inicial

El modelo teórico es una descomposición factorial de la inflación de la siguiente forma:

$$\Delta\%P_t = \beta_0 + \beta_1\Delta\%P_{t-1} + \beta_2\Delta\%P_t^{EUA} + \beta_3\%Y^g_{ap} + \beta_4\Delta\%e_t + I_t\delta\Delta\%e_t$$

donde:

$\Delta\%P_t$ Tasa de variación del Índice de Precios al Consumidor de Guatemala

β_0 Componente autónomo de la **tas de inflación**

$\Delta\%P_{t-1}$ Componente inercial de la inflación

$\Delta\%e_t$ Tasa de variación del tipo de cambio (tasa de depreciación del tipo de cambio)

$\Delta\%P_t^{EUA}$ Tasa de variación del Índice de Precios al Consumidor de Estados Unidos

Y_t^{brecha} Brecha relativa del producto respecto del potencial

I_t Variable dummy que es 1 si $\Delta\%P_{t-1} < \tau$ donde τ es el umbral y 0 en otro caso

El modelo considera a la infalción inercial ($\Delta\%P_{t-1}$) como la variable que define el estado del sistema, además de ello el uso de la variable dummy origina dos tipos de regímenes uno de inflación 'baja' y otro de inflación 'alta'.

Datos utilizados para ajsutar el modelo

Todos los datos se obtuvieron de fuentes oficiales como el Banco de Guatemala (<https://www.banguat.gob.gt/>) y U.S. Bureau of Labor Statics (<https://www.bls.gov/>). Además se adjunta la base de datos (<https://github.com/jorgeorenos/Pass-through/blob/cambios/Datos%20utilizados%20para%20el%20modelo.csv>) utilizada para ajustar el modelo².

Conjunto de datos utilizados

Inflación intermensual de Guatemala	Componente inercial	Inflación intermensual de Estados Unidos	Brecha del producto	Dpreciación del tipo de cambio
0.73	1.37	0.39977	0.53268	-0.84933
0.54	0.73	0.22753	-1.89777	-0.49274
0.43	0.54	0.39728	1.49072	0.65881
0.30	0.43	0.45223	-0.78380	0.26956
0.73	0.30	0.16882	-1.90104	0.37824
0.87	0.73	-0.28090	-1.36618	0.00026

Estimación de los umbrales de inflación

A continuación, se presenta el código con el cual se creó el conjunto de umbrales posibles así como el ajuste del modelo TAR especificado anteriormente por cada umbral posible. El número total de modelos estimados fue de 180.

```

# Creación de todos los posibles umbrales
# Número de umbrales fuera por debajo o arriba de la muestra

umbrales_fuera <- length(inercial) - round(dim(datos)[1] - dim(datos)[1]*0.3, digits = 0
)

# posibles umbrales del modelo
# inercial es un vector que contiene el rezago de la inflación, variable que define el e
stado del sistema

posibles <- sort(inercial)
posibles <- posibles[round((umbrales_fuera/2 + 1), 0):
                    (length(inercial)-round(umbrales_fuera/2,0))]

# Finalmente posibles es el vector que contiene el conjunto de umbrales posibles utiliza
dos para estimar el modelo

# Estimación de los 180 modelos

nombre_modelos <- c()
modelos <- list()
bases <- list()

# Ciclo para estimar y nombrar los modelos

for (i in c(1:length(posibles))) {

  # Se genera un nombre para cada modelo a fin de poder tener una correcta identificació
n

  nombre_modelos[i] <- c(sprintf("modelo_%s_%s", i, posibles[i]))

  # Se genera una base de datos para cada modelo
  # en esta base de datos d es la variable dummy que separa los regímenes inflacionarios

  m <- mutate(datos_modelo,
              d = ifelse(inercial<posibles[i], yes = 0, no = 1))

  # Bases es la lista que almacena las bases de datos utilizadas
  # Aunque era posible estimar los modelos sin almacenar las bases de datos se almacenar
on
  # para tener una referencia de ellas

  bases[[i]] <- m

  modelo <- lm(bases[[i]],
              formula = inf_gt_intermensual ~ 1 +
                deprec*d + inercial +
                inf_eua_intermensual + var_brecha - d)

  modelos[[i]] <- modelo
}

```

```

}

# Se coloca el nombre a cada base de datos y modelo

names(modelos) <- nombre_modelos
names(bases) <- nombre_modelos

```

Luego de la estimación de los modelos se procede al cálculo de la SSR de cada modelo.

```

# SSR es el vector que contiene la suma de residuos al cuadrado de cada modelo

ssr <- c()

for (i in c(1:length(posibles))) {

  ssr[i] <- sum(modelos[[i]]$residuals^2)

}

```

Identificación de los umbrales a partir de la función SSR

Una vez determinada la ssr se procede a la identificación de los umbrales escogiendo aquellos que minimicen la ssr en cada modelo. Dado que R no cuenta con una función nativa para la identificación de más de un mínimo se programó una función llamada *minimos* y que se deja aquí (<https://github.com/jorgeorenos/Pass-through/blob/cambios/C%C3%B3digo/minimos.R>) en dado caso el lector quiera revisarla.

```

# Cargando la función mínimos

source("minimos.R")

# Una vez se tiene la función se procede a determinar cuales son los umbrales del modelo

umbrales <- posibles[ssr %in% minimos(ssr, 4)]

names(modelos[ssr %in% minimos(ssr, 4)])

```

```

## [1] "modelo_18_0.14" "modelo_19_0.14" "modelo_95_0.44" "modelo_96_0.44"
## [5] "modelo_97_0.44" "modelo_135_0.56" "modelo_176_0.83" "modelo_177_0.83"

```


Como se observa los umbrales de inflación que minizan los errores son
 # 0.14, 0.44, 0.56 y 0.83% de infalción intermensual.

De forma gráfica se tiene la función SSR y la identificación de los mínimos

```
ggplot() +
  geom_line(aes(y = ssr, x = posibles), colour = "#3F6E9A", size = 1.3) +
  labs(title = "Estimación de los umbrales",
       y = "Suma de residuos al cuadrado", x = "Umbrales posibles",
       caption = "Elaboración propia") +

  geom_point(aes(x = umbrales,
                 y = ssr[ssr %in% minimos(ssr, 4)]), shape = 1, colour = "red",
             size = 5, stroke = 1.7) +

  theme_classic(base_size = 18)
```



Elaboración propia

Estiamción del modelo con dos umbrales, tres regímenes

Despues de distintas pruebas el modelo que mejores resultados presentó fue el que considera como los umbrales inflacionarios a $\tau_1 = 0.14\%$ y $\tau_2 = 0.83\%$ de inflación intermensual, algo que da origen a tres regímenes inflacionarios los cuales fueron:

- Inflación baja ($\Delta\%P_{t-1} < 0.14\%$)
- Inflación media ($0.14\% \leq \Delta\%P_{t-1} \leq 0.83\%$)
- Inflación alta ($\Delta\%P_{t-1} > 0.83\%$)

y el modelo quedó especificado la siguiente forma:

$$\Delta\%P_t = \beta_0 + \beta_1\Delta\%P_{t-1} + \beta_2\Delta\%P_t^{EUA} + \beta_3\%Y^{gap} + \beta_4\Delta\%e_t + I_t^1\delta_1\Delta\%e_t + I_t^2\delta_2\Delta\%e_t$$

Donde:

I_t^1 Variable dummy que es 1 en el régimen de inflación baja

I_t^2 Variable dummy que es 1 en el régimen de inflación media

Dejando como escenario base del ajuste del modelo TAR al régimen de inflación alta.

El código para el ajuste del modelo es el siguiente:

```
# Datos_TAR es la base de datos con la que se estimó el modelo especificado anteriormen
e
```

```
datos_TAR <- datos_modelo %>%
  mutate(dmen = ifelse(inercial < 0.14, yes = 1, no = 0),
         dentre = ifelse(inercial >= 0.14 & inercial <= 0.83,
                        yes = 1, no = 0))
```

```
attach(datos_TAR)
```

```
## The following object is masked _by_ .GlobalEnv:
##
##      inercial
```

```
TAR <- lm(datos_TAR, formula = inf_gt_intermensual ~ 1 +
         deprec*dmen + deprec*dentre +
         inercial + inf_eua_intermensual + var_brecha - dmen - dentre)
```

```
detach(datos_TAR)
```

Con los que se obtuvieron los siguientes resultados:

Coefficientes

	Estimate	Std. Error	t value	Pr(> t)
β_0	0.2536201	0.0386360	6.5643489	0.0000000
β_4	0.1040490	0.0831249	1.2517189	0.2118469
β_1	0.3244242	0.0612748	5.2945742	0.0000003
β_2	0.2388209	0.0657822	3.6304785	0.0003434
β_3	-0.0244780	0.0172573	-1.4184138	0.1573204
δ_1	-0.2493846	0.1267410	-1.9676706	0.0502158
δ_2	-0.0939505	0.0959698	-0.9789588	0.3285505

Estimación del efecto pass-through

finalmente la estimación del efecto está dada por las interacciones que propician las variables dummy.

Régimen inflacionario	Interacción	Pass-through
Inflación alta ($\Delta\%P_{t-1} > 0.14\%$)	β_4	0.10405
Inflación media ($0.14\% \leq \Delta\%P_{t-1} \leq 0.83\%$)	$\beta_4 + \delta_2$	0.0101
Inflación baja ($\Delta\%P_{t-1} < 0.14\%$)	$\beta_4 + \delta_1$	-0.14533

Comprobación de los supuestos

En este apartado se hace una comprobación de los supuestos de MCO para el modelo ajustado.

Normalidad

Las pruebas de Jarque Bera y Shapiro muestran normalidad de los residuos al 1%.

```
tseries::jarque.bera.test(TAR$residuals)
```

```
## Registered S3 method overwritten by 'quantmod':  
##   method      from  
##   as.zoo.data.frame zoo
```

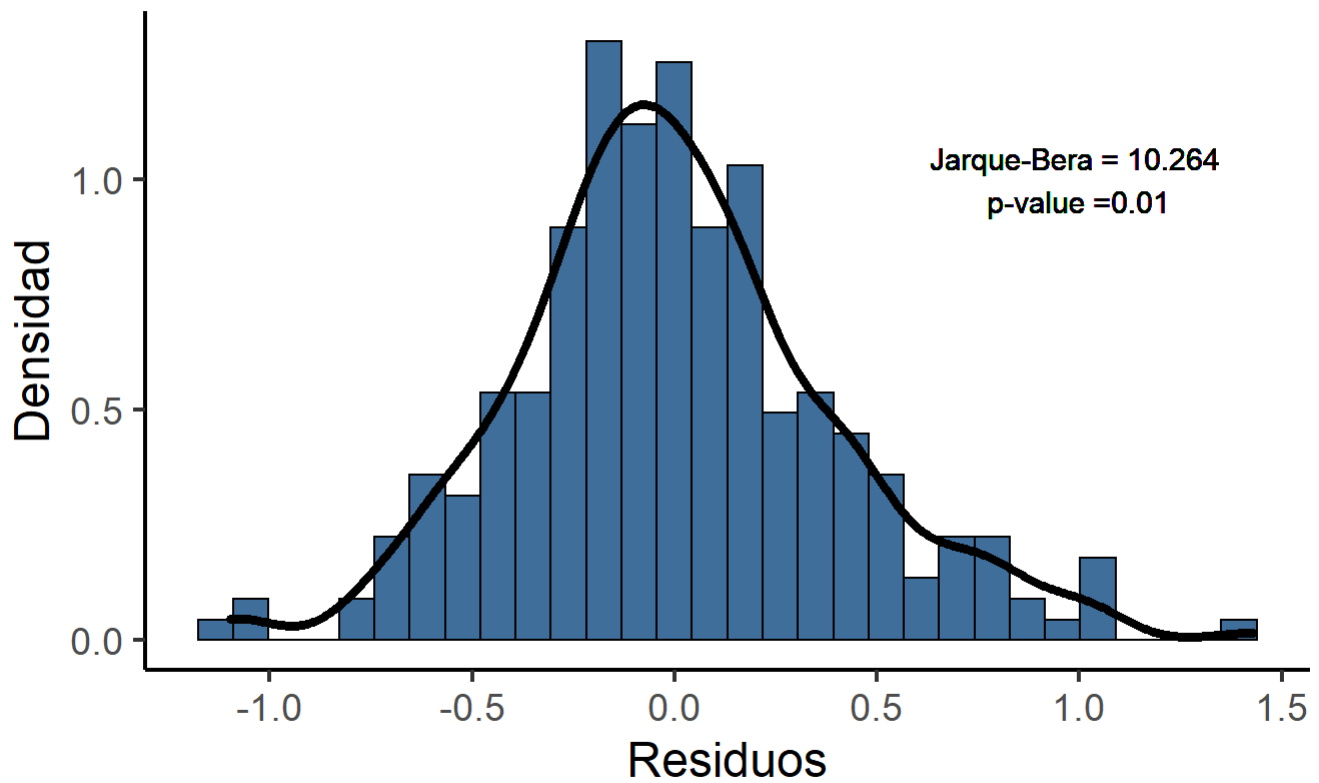
```
##  
##  Jarque Bera Test  
##  
## data:  TAR$residuals  
## X-squared = 10.264, df = 2, p-value = 0.005906
```

```
shapiro.test(TAR$residuals)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  TAR$residuals  
## W = 0.98592, p-value = 0.01278
```

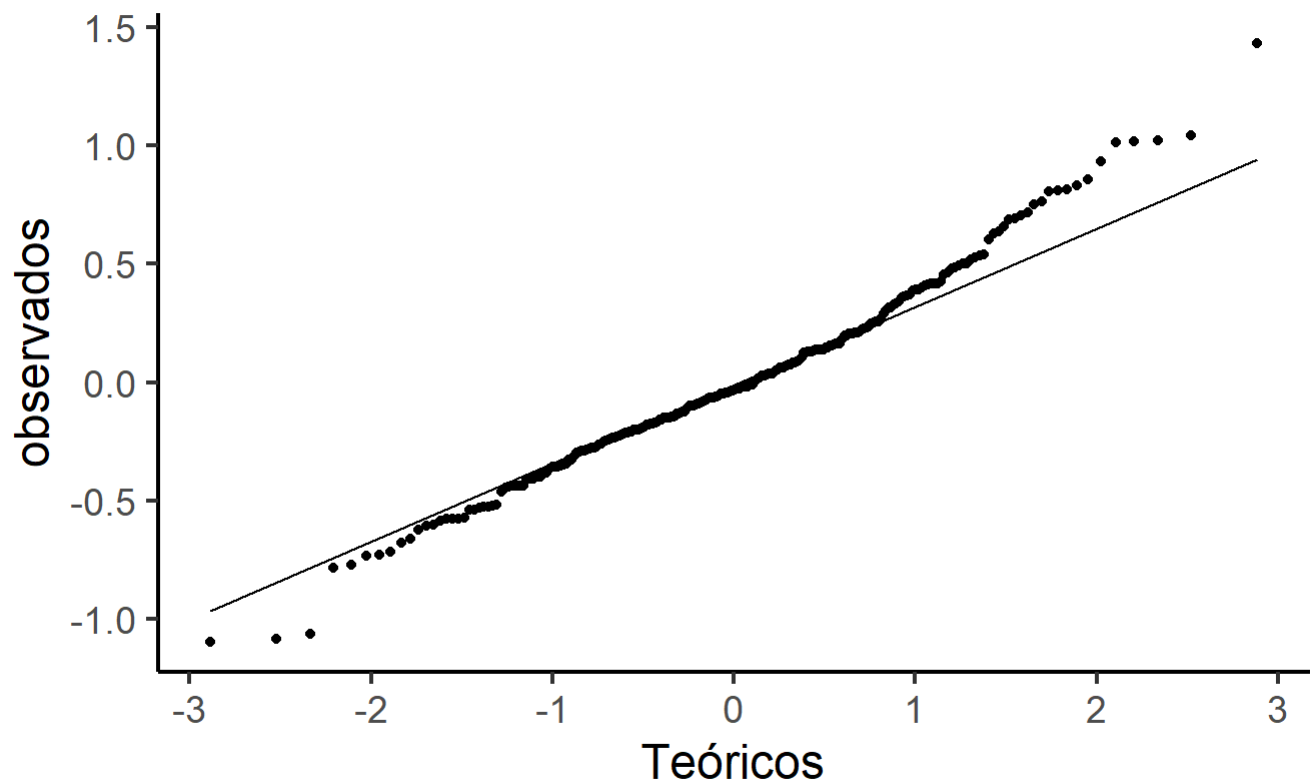
```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

Histograma de los residuos



Elaboración propia

Gráfico cuantil-cuantil



Elaboración propia

Autocorrelación

La prueba de Breusch-Godfrey muestra que no hay autocorrelación de los errores.

```
lmtest::bgtest(TAR)
```

```
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: TAR
## LM test = 1.19, df = 1, p-value = 0.2753
```

Heterocedasticidad

La prueba Breusch-Pagan de heterocedasticidad muestran una varianza homocedastica.

```
lmtest::bptest(TAR)
```

```
##
## studentized Breusch-Pagan test
##
## data: TAR
## BP = 6.5717, df = 6, p-value = 0.3623
```

Multicolinealidad

Todos los factores de inflación de la varianza son inferiores a 5 por lo que el modelo no sufre de problemas de multicolinealidad.

```
car::vif(TAR)
```

```
## there are higher-order terms (interactions) in this model
## consider setting type = 'predictor'; see ?vif
```

```
##           deprec           inercial inf_eua_intermensual
##           4.799170           1.157172           1.048518
##           var_brecha         deprec:dmen         deprec:dentre
##           1.022142           1.794247           3.926314
```


Análisis de varianzas y covarianzas

Siguiendo la recomendación de Baqueiro, Díaz de Leon & Torres (2004) se calculan las covarianzas entre tipo de cambio y precios para cada uno de los regímenes así como la varianza del tipo de cambio. La razón de ello es para determinar el motivo por el cual el coeficiente asociado al pass-through disminuye.

$$\beta_i = \frac{cov_{x_i y}}{var_{x_i}}$$

Si la covarianza entre el tipo de cambio y los precios disminuye el coeficiente también lo hará algo que también sucede si aumenta la varianza del tipo de cambio.

regimen	covarianza	varianza
inflación alta	0.0218614	0.6030626
inflación baja	-0.0315643	0.3741780
inflación media	-0.0028357	0.4230115

1. Se elimina el 15% de las observaciones extremas superiores e inferiores. 
2. Para estimar la brecha del producto se utilizó el Índice Mensual de la Actividad Económica (IMAE), serie que fue desestacionalizada para posteriormente aplicarse el filtro Hodrick-Prescott. el tratamiento de la serie lo puede encontrar en este aquí: serie IMAE (<https://jorgeorenos.github.io/serie-IMAE/>) 